ÉVOLUTION L'INFLATION AU CANADA : ANALYSE DE L'IPC-GLOBAL ET L'IPC-HAEI

GROUPE 4

Boga

TABLES DES MATIÈRES

1 Description des données

1.1 Présentation des séries.....3

1.2 Analyses des séries..... 4

2. Filtrage

2.1 Filtrage linéaire..... 5-6

2.2 Filtrage exponentiel..... 6-7

2.3 Stationnarité des séries résiduelles.....7-10

3. Différenciation

3.1 Différenciation d'ordre 11-12

3.2 Stationnarité des séries différenciées..... 13-14

4. Stationnarité

4.1 Choix de la méthode pour la stationnarité.....13

4.2 Analyse de l'autocorrélation.....13-14

5.Sélection des ordres des modèles ARMA

5.1 Illustration des fonctions d'autocorrélation ACF et d'autocorrélation partielle PACF.15-18

5.2 Hypothèses des ordres de modèles pour chaque séries stationnaires.....18

6. Estimation des modèles ARMA

6.1 Division de l'échantillon 18

6.2 Estimation d'un modèle ARMA(p,q).....18-20

6.3 Estimation d'un second modèle imbriqué.....1

6.4 Estimation, présentation des paramètres estimés..... 1

7. Tests diagnostics

7.1 Calcul de l'AIC et BIC 1

7.2 Calcul de la statistique du ratio de vraisemblance et de la valeur-p..... 1

7.3 Calcul des valeurs ajustées, de l'erreur quadratique moyenne..... 1

7.4 Recommandation du modèle ARMA(p,q)..... 1

8. Modèle bivarié et corrélations croisées

8.1 Analyse des propriétés statistiques.....1

8.2 Calcul et représentation graphique de la fonction de corrélation (CCF).....1

8.3 Test des résidus..... 1

8.4 Explication des hypothèses.....1

Références

Annexes

1. **Description des données**

1.1 **Présentation des séries**

Nous avons choisi comme séries l'indice des prix à la consommation global et l'indice des prix à la consommation hors alimentation, énergie, effets des modifications des impôts indirects comme mesures de l'inflation au Canada.
Dans une analyse de l'inflation, utiliser à la fois l'IPC-GLOBAL et l'IPC-HAEI permet d'avoir une vision à la fois générale et plus précise de l'évolution des prix. L'IPC-GLOBAL est la mesure officielle de l'inflation telle que vécue par les ménages, car il inclut tous les biens et services consommés. Il montre donc directement comment les hausses de prix affectent le pouvoir d'achat, ce qui est essentiel pour comprendre les effets économiques et sociaux de l'inflation.
De son côté, l'IPC-HAEI exclut les éléments les plus instables comme l'alimentation, l'énergie et les changements d'impôts indirects. Cela permet de mieux suivre la tendance de fond de l'inflation, sans être perturbé par des variations temporaires ou extérieures. Comparer les deux indices aide donc à faire la différence entre une inflation passagère et une inflation plus durable, ce qui est particulièrement utile pour les décisions de politique monétaire ou les prévisions économiques.
Les données sur l'IPC-GLOBAL viennent de la banque du canada (v41690973), ainsi que celles de l'IPC-HAEI (v41755376). Les deux séries sont de fréquence mensuelle, en pourcentage, et vont de 1995 à 2024.
Nous pouvons voir sur les graphiques ci-dessous les graphiques montrant l'évolution de nos séries.

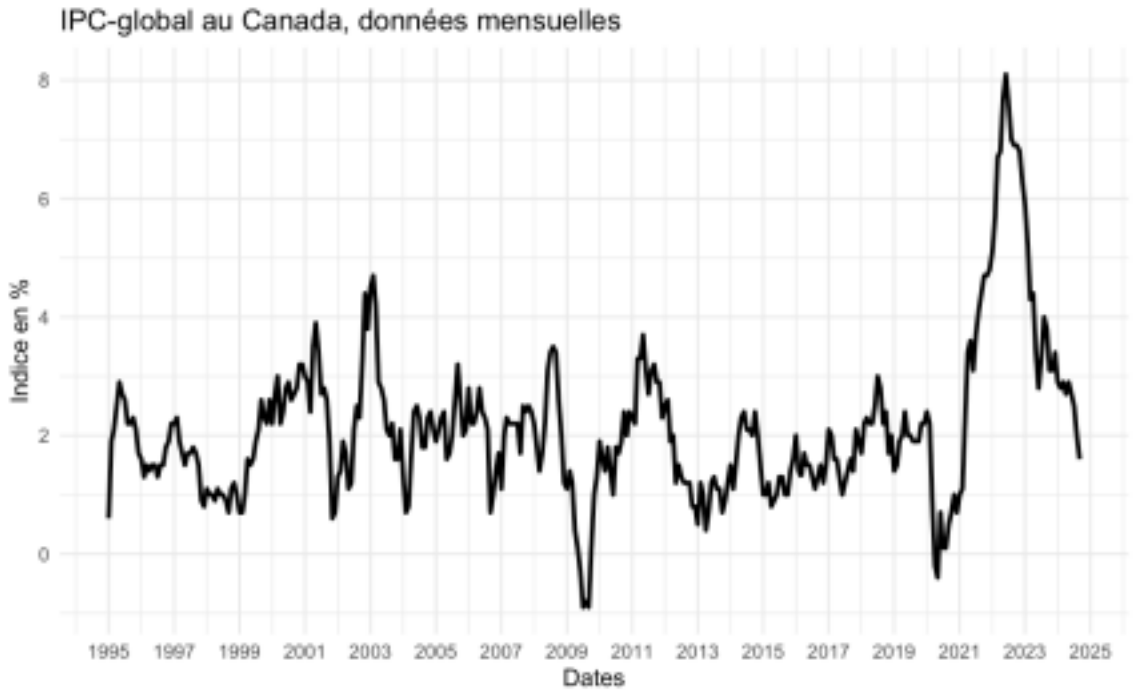

3

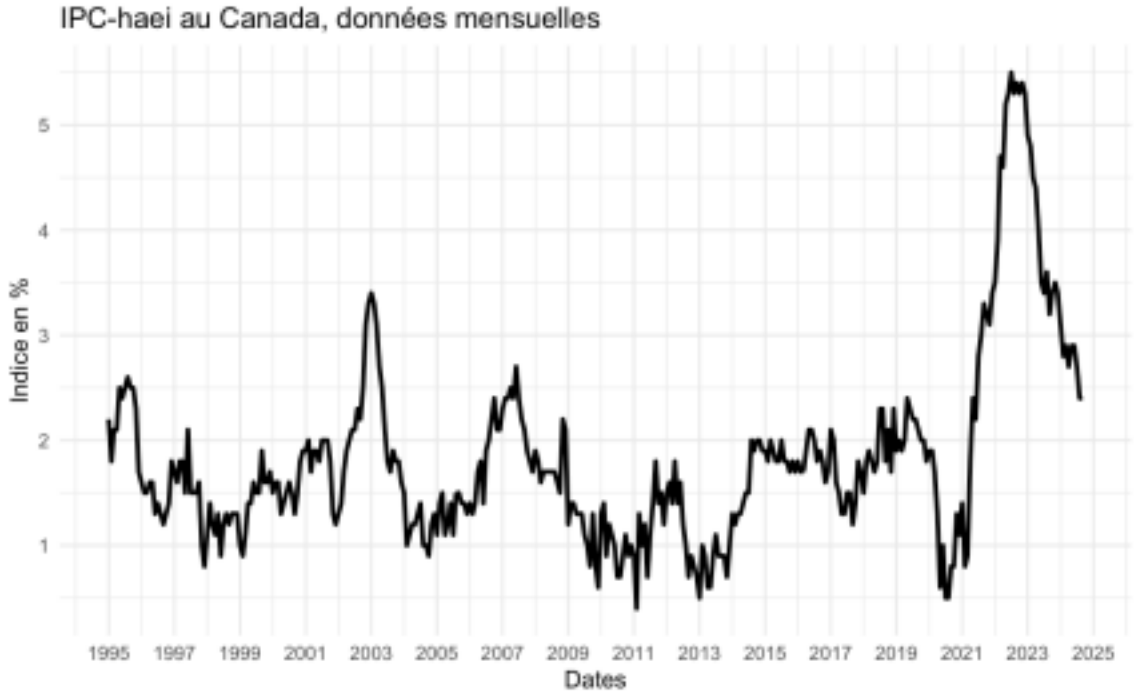

1.2 Analyses et transformations

Pour la période de 1995 à 2024, nous utilisons la commande ci-dessous pour vérifier que nous n'avons pas de données manquantes pour les deux séries.

```
sum(is.na(donnees))
```

```
## [1] 0
```

Nous voyons donc que nous n'avons pas de données manquantes.
Présentons quelques statistiques descriptives pour nos séries:

Série	Moyenne	Écart-type	Minimum	Maximum
IPC-HAEI	1.83	0.91	0.40	5.50
IPC-GLOBAL	2.13	1.31	-0.90	8.10

Nous pensons que nos séries ne nécessitent pas de transformations. En se basant sur la visualisation des graphiques, nous voyons qu'avant 2020, l'IPC-GLOBAL avait une tendance générale oscillante entre -0.9 et environ 5, laissant penser à une composante saisonnière. Après cette année il y a eu un pic, probablement à cause de la COVID-19, qui revient en dessous de 4 vers 2023, nous pensons donc qu'il y a un effet de saisonnalité à la base de ces variations, donc une tendance saisonnière. Il en ait de même pour l'IPC-HAEI, où nous voyons aussi un effet de saisonnalité avec une oscillation entre 0 et 3 avant 2020, et ensuite un pic après cette année qui redescend après 2023 environ. Nous voyons aussi un léger pic pour les deux séries en 2003. Une analyse plus approfondie permettrait d'expliquer plus précisément ces irrégularités

2. Filtrage

2.1 Filtrage linéaire

Nous avons appliqué un filtre de lissage linéaire aux deux séries. Nous avons choisi 2 paramètres arbitraires et pour le choix final, nous avons pris le paramètre qui minimise le plus les erreurs.

Pour l'IPC-GLOBAL :

q	MSE
2	0.082
12	0.543

Pour l'IPC-HAEI :

q	MSE
2	0.027
12	0.138

Le paramètre q=2 minimise les erreurs, donc il sera notre paramètre de lissage linéaire. Voici les graphiques des séries avec lissage linéaire.

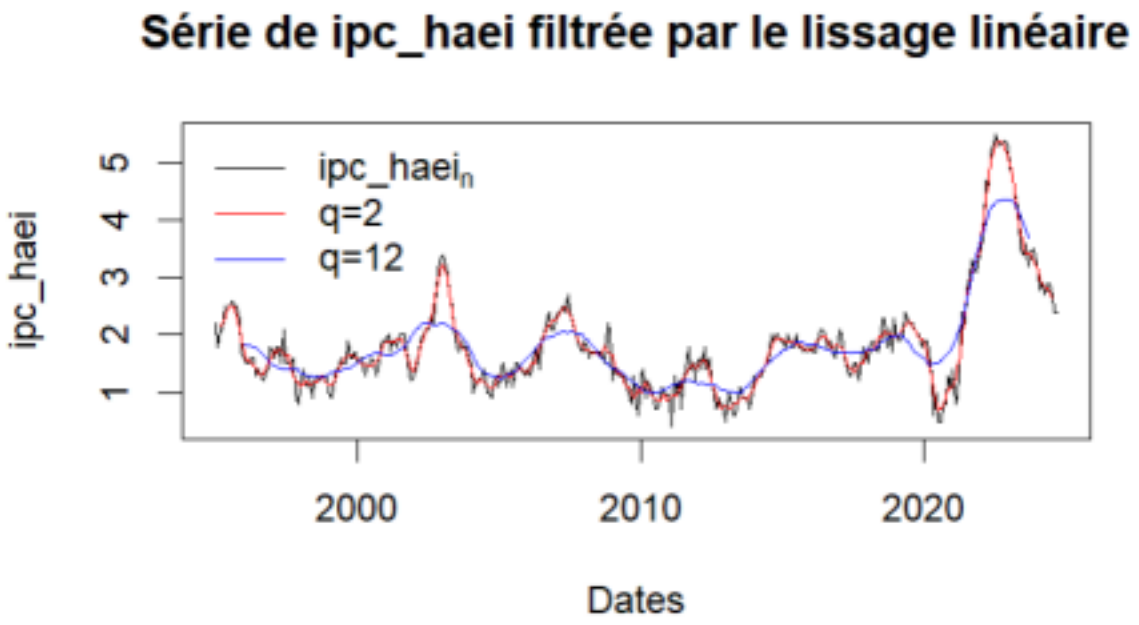

5

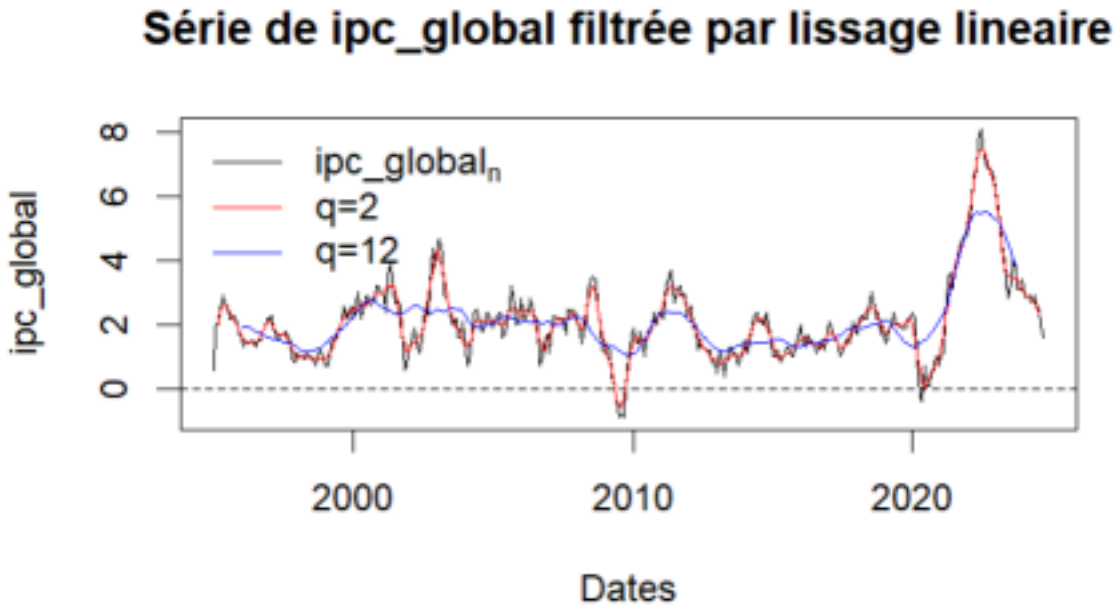

2.2 Filtrage exponentiel

Pour le filtrage exponentiel, nous avons procédé de la même façon, en choisissant 3 paramètres alpha.

Pour l'IPC-HAEI :

alpha	MSE
0.1	0.250
0.5	0.021

0.9	0.0006

Pour l'IPC-GLOBAL :

alpha	MSE
0.1	0.755
0.5	0.072
0.9	0.002

alpha=0.9 donne les plus petites erreurs, donc nous allons utiliser ce paramètre pour le filtrage exponentiel. Les graphiques avec toutes les valeurs d'alpha sont présentés ci-dessous.

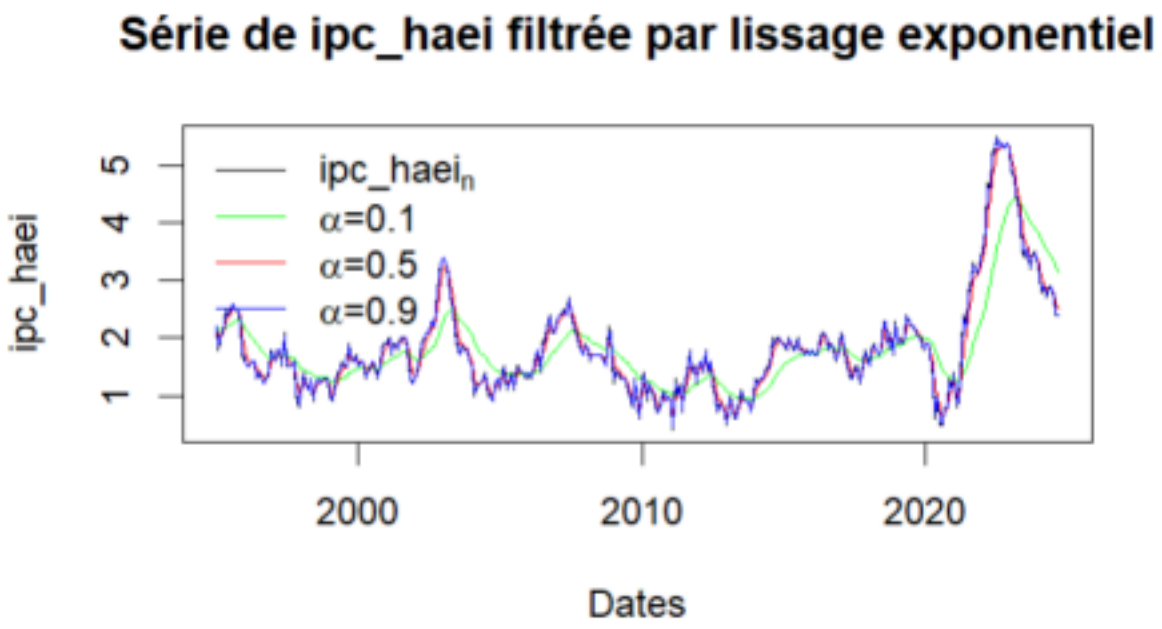

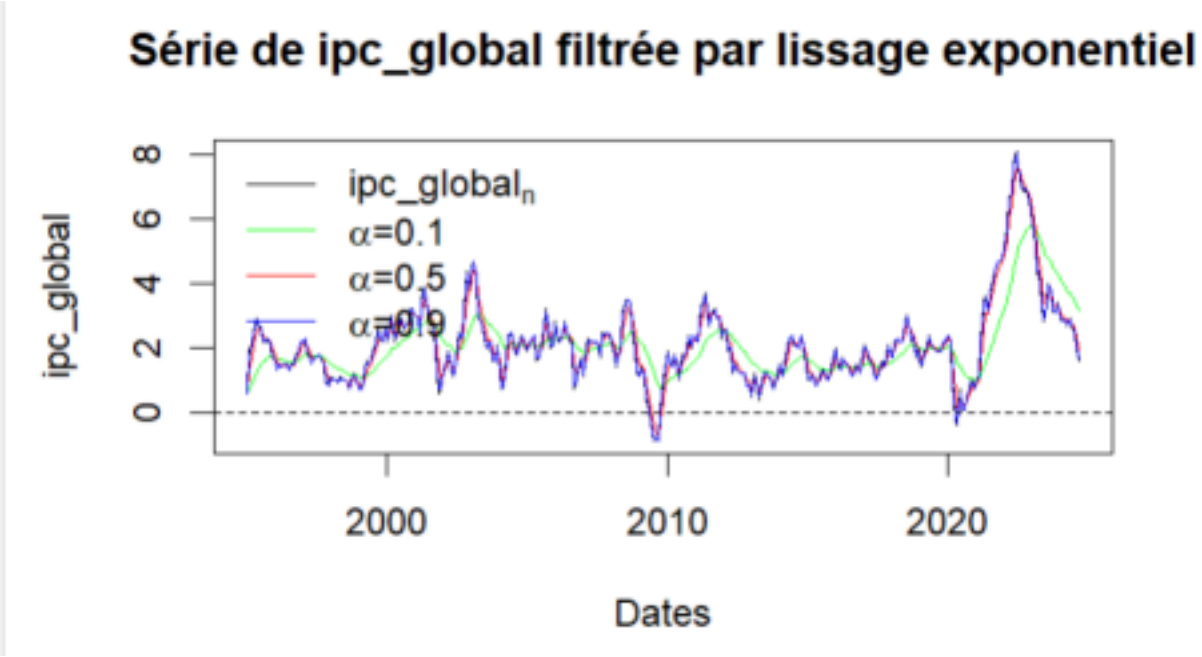

2.3 Stationnarité des séries résiduelles

Nous avons analysé les résidus des séries filtrées avec les paramètres q=2 pour le lissage linéaire et alpha=0.9 pour le lissage exponentiel. Pour l'IPC-HAEI, avec le lissage linéaire, la moyenne de la série résiduelle est 0.0009 et la variance est 0.027. Avec le lissage exponentiel, la moyenne est de 0.00006 et la variance 0.00068. Concernant l'IPC-GLOBAL, la moyenne de la série résiduelle du lissage linéaire est 0.0025 et la variance 0.0823. Et avec le lissage exponentiel, la moyenne est 0.00032 et la variance 0.002. Nous constatons que les moyennes sont plus petites avec le lissage exponentiel, et que les variances sont plus proches de 0, laissant penser que les séries ne présentent plus de tendance après l'application des filtres.

Les graphiques des résidus dans chacun des cas se trouvent ci-dessous.

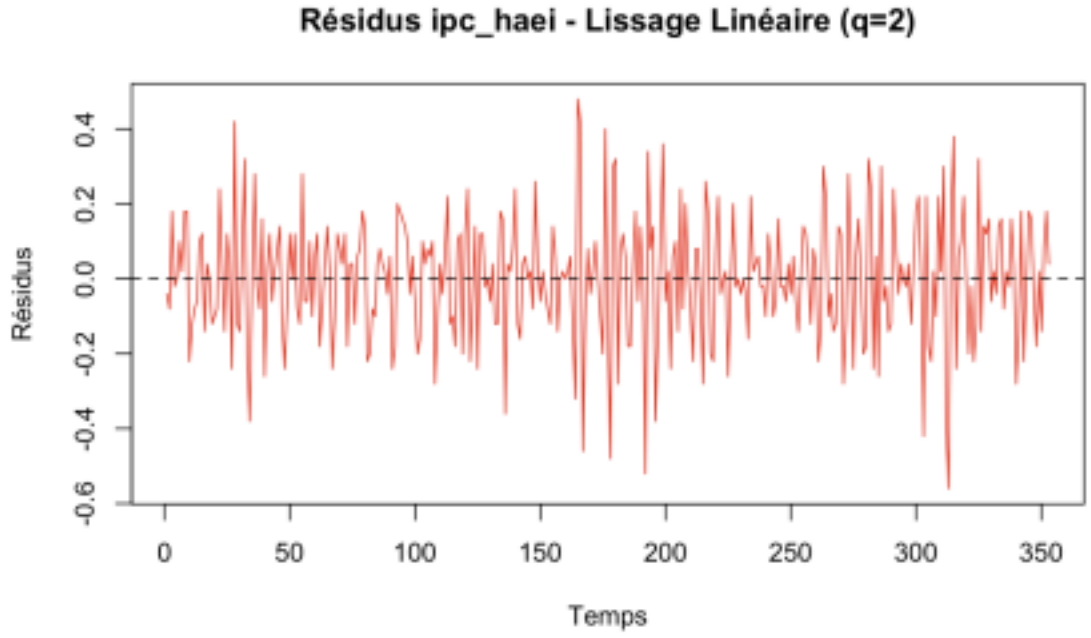
Résidus ipc_haei - Lissage Linéaire (q=2)
Résidus
0.4
0.2
0.0
-0.2
-0.4
-0.6
0
50
100
150
200
250
300
350
Temps

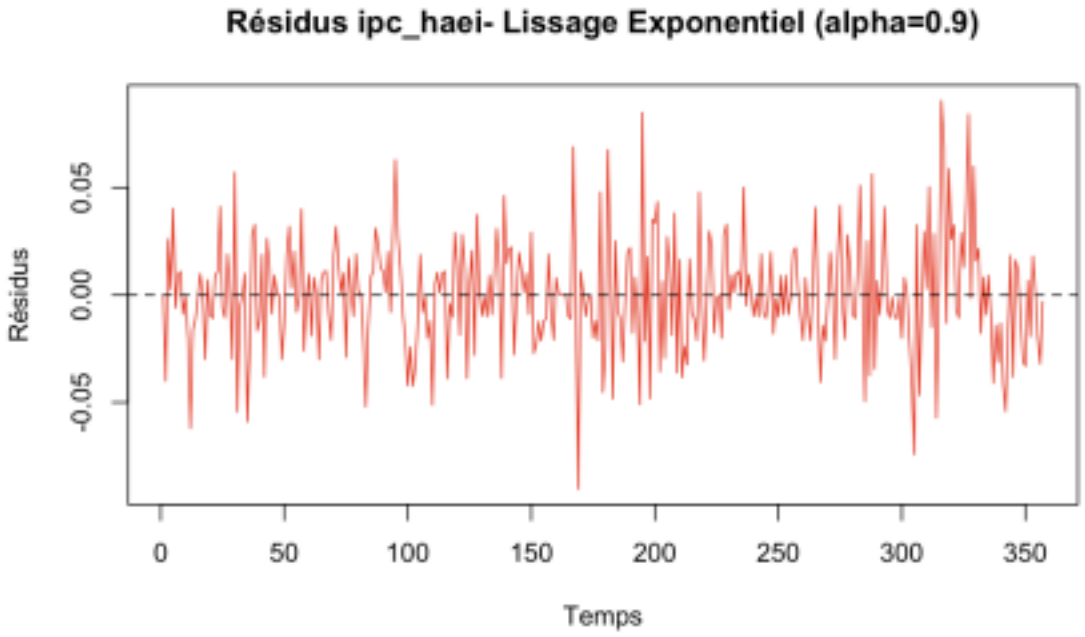
Résidus ipc_haei- Lissage Exponentiel (alpha=0.9)
Résidus
0.05
0.00
-0.05
0
50
100
150
200
250
300
350
Temps

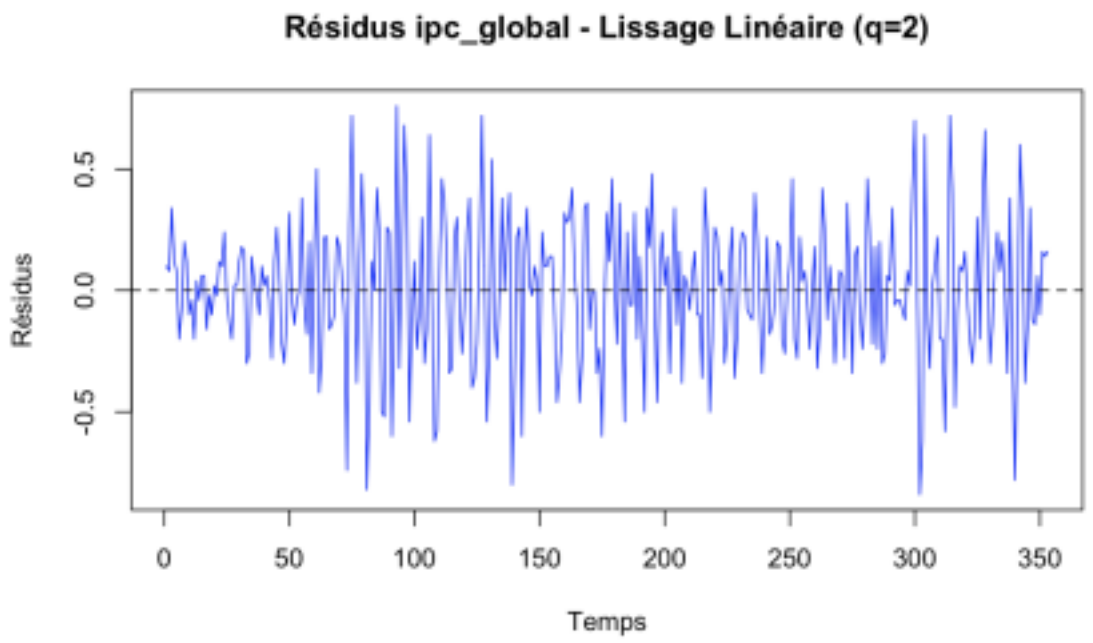

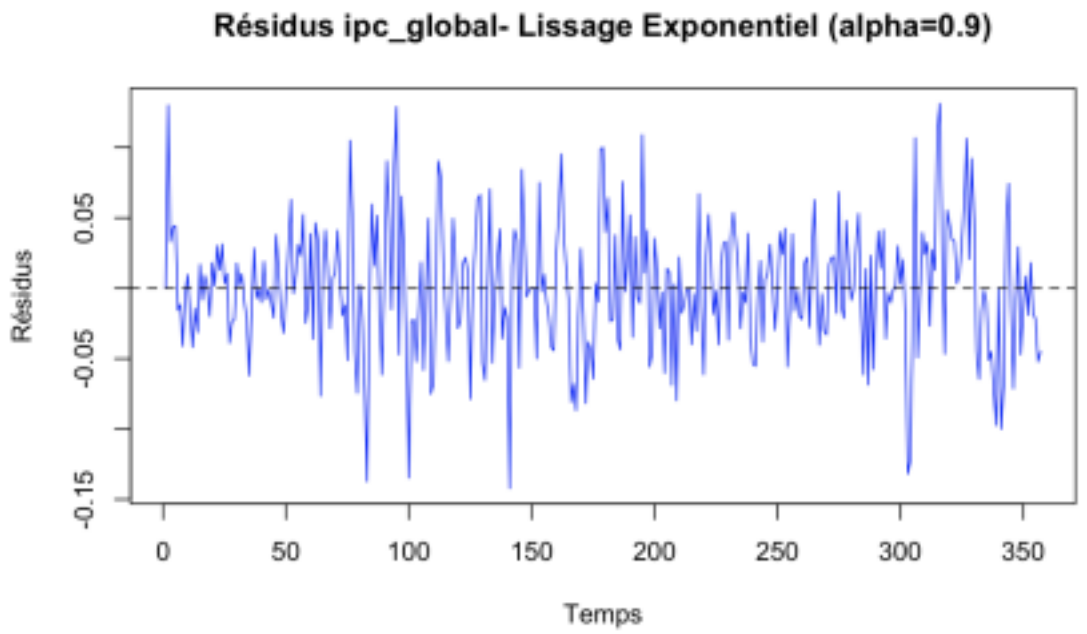

Pour tester la stationnarité, nous avons d'abord utilisé le test augmenté de Dickey-Fuller ADF et nous voyons que toutes les séries sont stationnaires à 5% les statistiques t étant plus petites que la valeur critique -2.89.

```
Statistique de test ADF : -20.71099
Valeurs critiques (1% | 5% | 10%) : -3.5 -2.89 -2.58
 Hypothèse de non-stationnarité rejetée (stationnaire à 5%)
Statistique de test ADF : -19.20601
Valeurs critiques (1% | 5% | 10%) : -3.5 -2.89 -2.58
 Hypothèse de non-stationnarité rejetée (stationnaire à 5%)
Statistique de test ADF : -6.725731
```



```
Valeurs critiques (1% | 5% | 10%) : -3.5 -2.89 -2.58
Hypothèse de non-stationnarité rejetée (stationnaire à 5%)
```

```
Statistique de test ADF : -14.8782
Valeurs critiques (1% | 5% | 10%) : -3.5 -2.89 -2.58
 Hypothèse de non-stationnarité rejetée (stationnaire à 5%)
```

Ensuite, pour renforcer les résultats, nous utilisons le test porte-manteau de Ljung-Box, et nous trouvons qu'il y a des preuves que la série résiduelle de l'IPC-HAEI avec lissage exponentielle a une autocorrélation nulle à 5%, la valeur p étant supérieur au seuil, et donc que la série est possiblement stationnaire.

```
Box-Ljung test

data: resid_lisa3_ipc_haei
X-squared = 3.6747, df = 6, p-value = 0.7206
```

Nous utilisons aussi le test porte-manteau de McLeod-Li, et à 5% la série résiduelle du lissage exponentiel de l'IPC-GLOBAL a une autocorrélation non significative et donc une possible stationnarité. Les tests sur les autres séries donnent des valeurs-p inférieures à 5%, mais cela ne vient pas forcément contredire l'hypothèse de stationnarité. Mais nous concluons quand même que nous avons de meilleurs résultats de stationnarité avec le lissage exponentiel pour les 2 séries.

```
Box-Ljung test

data: resid_lisa3_ipc_global^2
X-squared = 10.89, df = 6, p-value = 0.09184
```


3. Différenciation

3. 1 Différenciation d'ordre 1

La différenciation permet de savoir si une série chronologique est stationnaire, sans tendance ni saisonnalité. Elle permet de transformer une série qui fluctue en une série équilibrée autour de zéro.

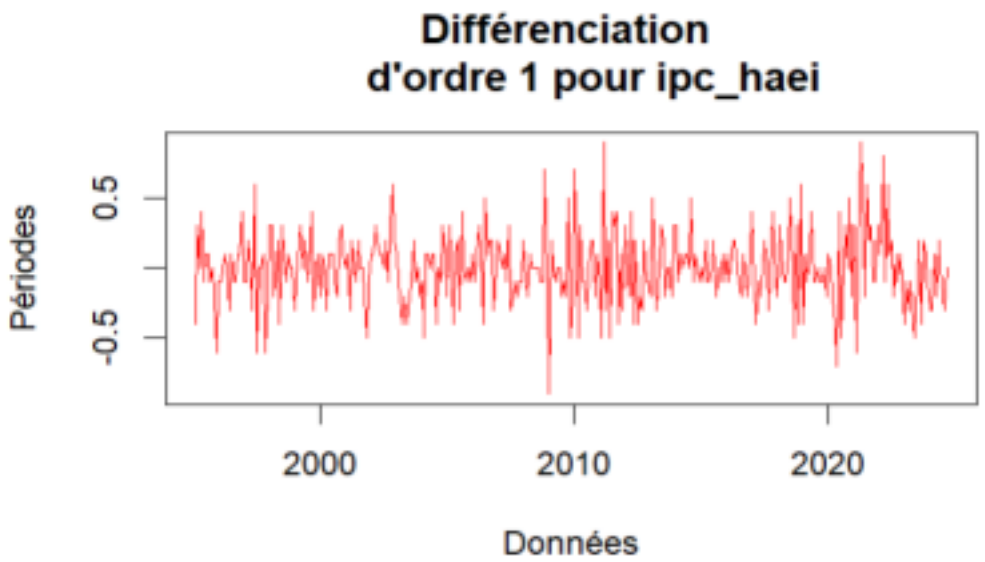

Après la différenciation d'ordre 1, nous remarquons que la série IPC-HAEI semble stationnaire.

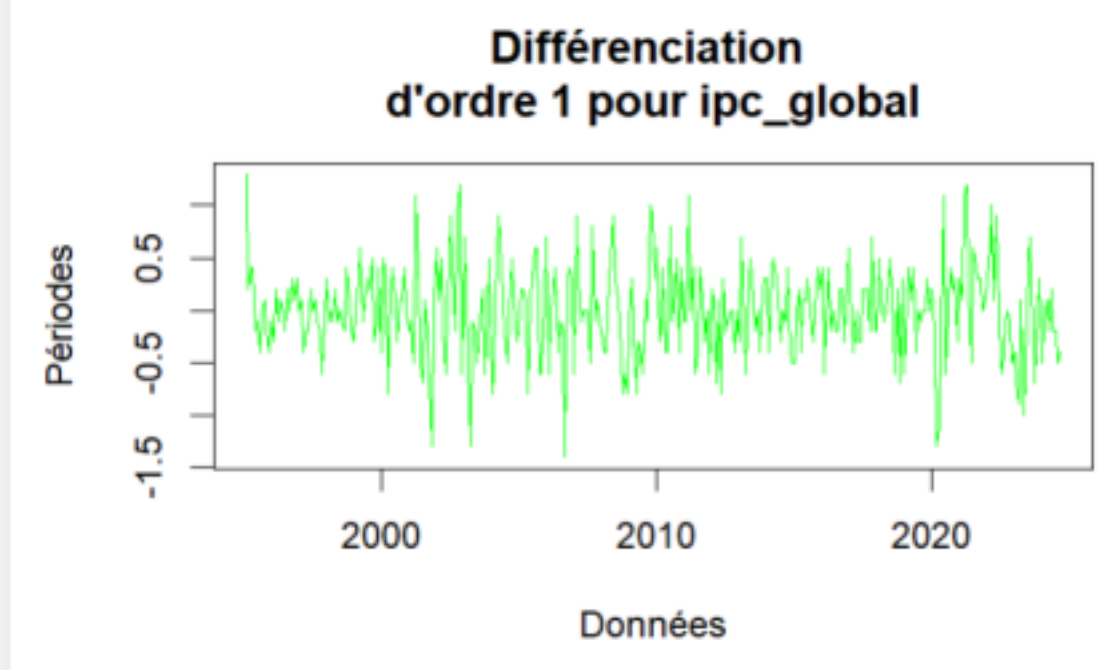

Après la différenciation d'ordre 1, nous remarquons que la série IPC-GLOBALsemble stationnaire.

3.2 Stationnarité des séries différenciées

Série	Moyenne	Variance
IPC_HAEI	0.0005617978	0.06901377

Série	Moyenne	Variance
IPC-GLOBAL	0.002808989	0.1958794

ADF

```
Statistique de test ADF : -16.47116
Valeurs critiques (1% | 5% | 10%) : -3.5 -2.89 -2.58
 Hypothèse de non-stationnarité rejetée (stationnaire à 5%)
Statistique de test ADF : -21.26734
Valeurs critiques (1% | 5% | 10%) : -3.5 -2.89 -2.58
 Hypothèse de non-stationnarité rejetée (stationnaire à 5%)
Statistique de test ADF : -4.276416
Valeurs critiques (1% | 5% | 10%) : -3.5 -2.89 -2.58
 Hypothèse de non-stationnarité rejetée (stationnaire à 5%)
Statistique de test ADF : -4.367974
Valeurs critiques (1% | 5% | 10%) : -3.5 -2.89 -2.58
 Hypothèse de non-stationnarité rejetée (stationnaire à 5%)
```

BOX PIERCE

```
data: diff1_ipc_haei
X-squared = 7.7171, df = 6, p-value = 0.2596

data: diff1_ipc_global
X-squared = 10.741, df = 6, p-value = 0.09673
```

4. Stationnarité

4.1 Choix de la méthode pour la stationnarité

En se basant sur les différents tests, le filtrage exponentiel et la différentiation donnent des séries stationnaires et de moyennes et variances constantes. Mais le filtrage exponentiel nous donne des variances plus petites donc nous préférons utiliser cette méthode. Rappelons que la moyenne est de 0.00006 et la variance 0.00068 pour l'IPC-HAEI et l'IPC-GLOBAL la moyenne est 0.00032 et la variance 0.002.

4.2 Analyse de l'autocorrélation

En se servant d'une fonction qui calcule l'autocorrélation d'une série chronologique stationnaire à un horizon h, nous avons calculé les autocorrélations aux horizons h=0,1,...,20 à 95%. Ci-dessous se trouve les illustrations des autocorrélations.

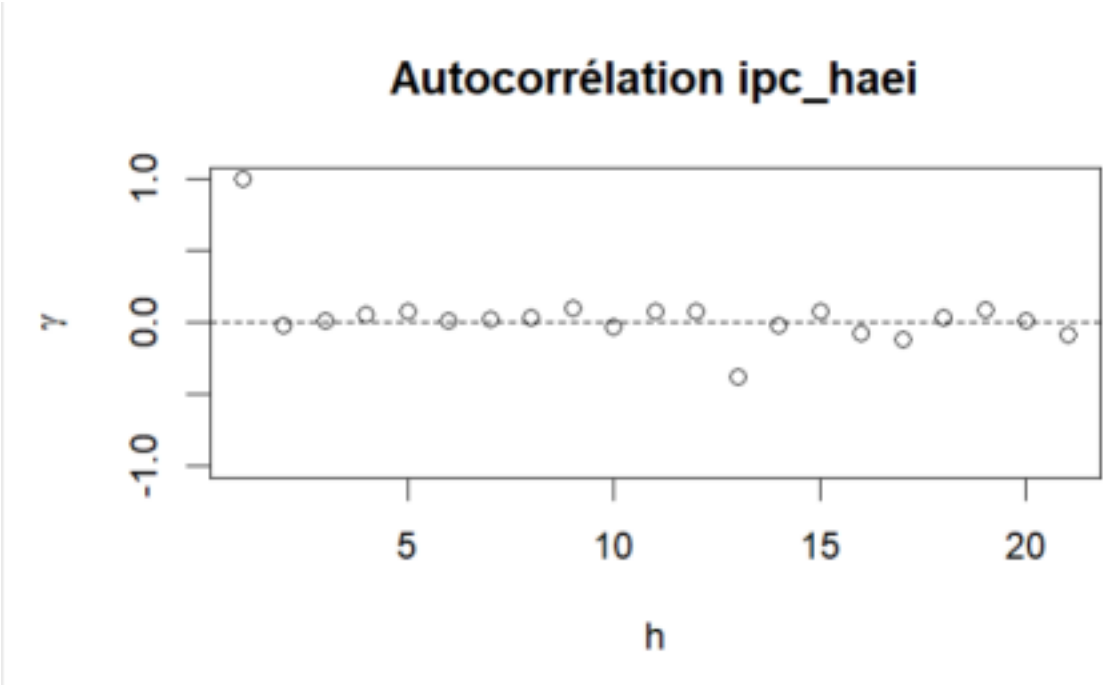

13

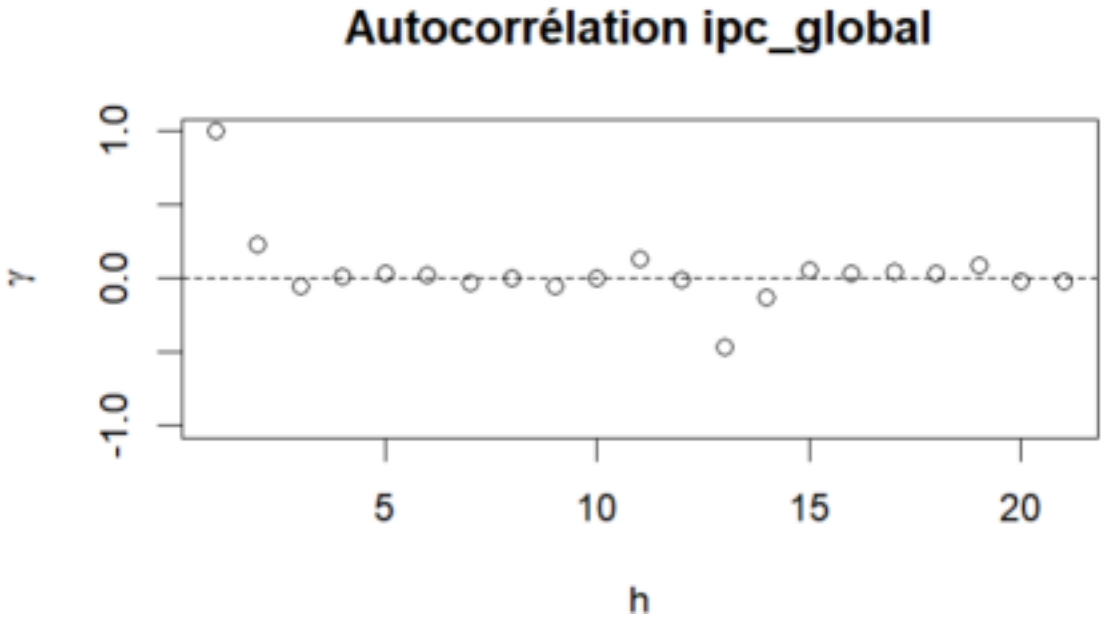

14

5. Sélection des ordres des modèles ARMA

5.1 Illustration des fonctions d'autocorrélation ACF et d'autocorrélation partielle PACF.

<u>Série ipc_haei:</u>

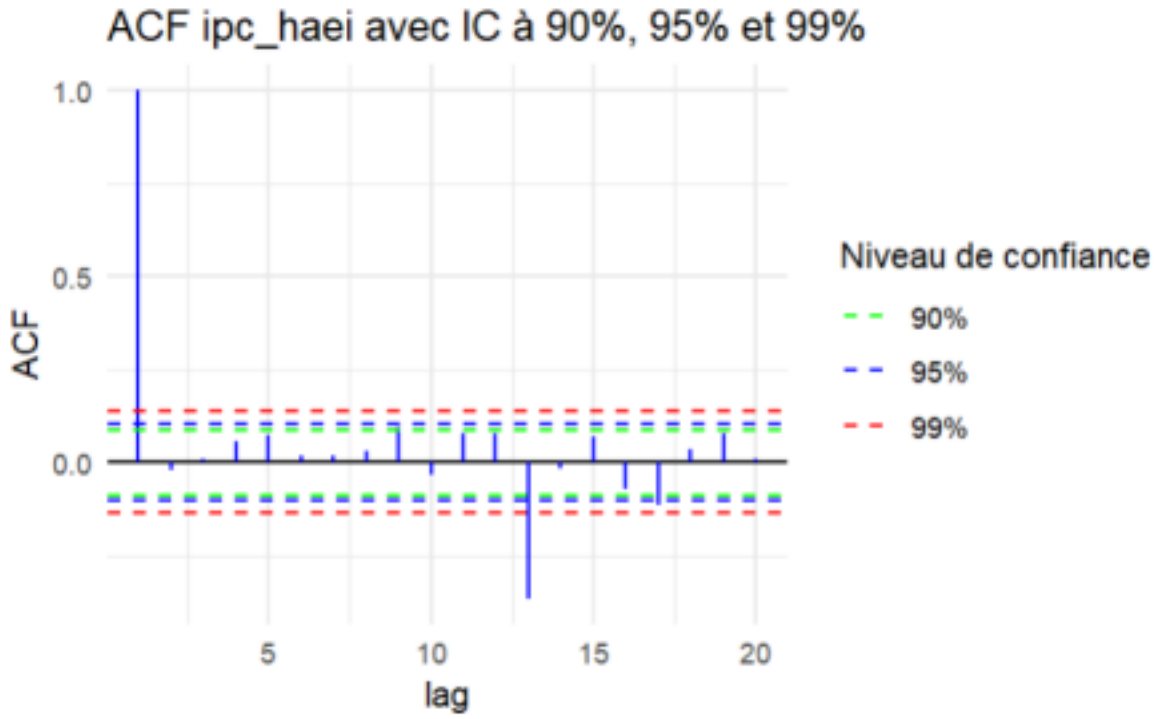

<u>Identification des horizons:</u>

A 90%, ACF n'est pas statistiquement différentes de zéro aux lags de 2 à 8, 10 à 12, 14 à 16, puis de 18 à 20.

A 95%, ACF n'est pas statistiquement différentes de zéro aux lags de 2 à 12, 14 à 16 puis de 18 à 20.

A 99%, ACF n'est pas statistiquement différentes de zéro aux lags de 2 à 12, puis de 14 à 20.

Identification des horizons:

A 90%, PACF n’est pas statistiquement différentes de zéro aux lags de 1 à 7, de 9 à 11, de 13 à 15, puis de 17 à 20.

A 95%, PACF n’est pas statistiquement différentes de zéro aux lags de 1 à 11, puis de 13 à 20.

A 95%, PACF n’est pas statistiquement différentes de zéro aux lags de 1 à 11, puis de 13 à 20.

Série ipc_global:

16

Identification des horizons:

A 90%, ACF n’est pas statistiquement différentes de zéro aux lags de 3 à 8, 10, puis de 13 à 20.

A 95%, ACF n’est pas statistiquement différentes de zéro aux lags de 3 à 8, 10, puis de 13 à 20.

A 99%, ACF n’est pas statistiquement différentes de zéro aux lags de 3 à 10, puis de 12 à 20.

Identification des horizons:

A 90%, PACF n’est pas statistiquement différentes de zéro aux lags de 3 à 9, 10, puis de 13 à 20.

A 95%, PACF n’est pas statistiquement différentes de zéro aux lags de 3 à 9, 10, puis de 13 à 20.

A 99%, PACF n’est pas statistiquement différentes de zéro aux lags de 2 à 11, puis de 13 à 20.

5.2 Hypothèses des ordres de modèles pour chaque séries stationnaires.

Concernant l’IPC-HAE, en visualisant le graphique ACF, une décroissance des autocorrélations se fait voir après le lag 1. Nous pensons donc à un MA(1). Quant au PACF, sauf au lag de 13 les autocorrélations sont proches de 0, et ce graphique nous aide sur l’ordre du modèle AR, nous suggérons q=0. Donc pour cette série nous suggérons un ARMA(0,1), soit MA(1). Pour l’IPC-GLOBAL, en visualisant le graphique ACF, une décroissance des autocorrélations se fait voir après les deux premiers lag. Ce qui nous fais penser à un MA(2). En regardant le PACF, sauf au lag de 13 nous observons une décroissance des autocorrélations qui sont proches de 0 après le lag 1, nous suggérons donc q=1. Ce qui nous donne pour cette série un ARMA(1,2).

6. Estimation des modèles ARMA

6.1 **Estimation des modèles simples et imbriqués avec méthode de maximum de vraisemblance**

Nous avons divisé notre échantillon en deux ensembles, un ensemble d'entraînement contenant 80% des observations et le reste constitue l’ensemble de test. Avec la méthode de maximum de vraisemblance nous avons estimé un modèle sur l’ensemble d'entraînement ainsi que sur l’ensemble de test. Nous avons choisi comme paramètres, ceux donnés dans nos hypothèses : MA(1) pour l’IPC-HAEI et ARMA(1,2) pour l’IPC-GLOBAL pour les deux ensembles. Ensuite dans le souci d’une bonne estimation, nous avons estimé des modèles imbriqués aux premiers, ARMA(1,1) pour le

MA(1) et MA(2) pour le ARMA(1,2), afin de les comparer et choisir le meilleur modèle.

6.2 **Comparaison des modèles**

Les paramètres estimés et leurs écarts-types pour chacun des modèles sont présentés ci-dessous à partir de sorties R.

Pour l'IPC-GLOBAL, au niveau du modèle MA(1), nous avons dans l'ensemble d'entraînement :

Dans l'ensemble de test :

Pour le modèle ARMA(1,1) dans l'ensemble d'entraînement :

Dans l'ensemble de test :

Pour l'IPC-HAEI, au niveau du modèle ARMA(1,2) dans l'ensemble d'entraînement:

Dans l'ensemble de test :

Pour le modèle MA(2) dans l'ensemble d'entraînement :

Dans l'ensemble de test :

Nous voyons que pour les modèles plus simples MA(1) et MA(2), les écarts-types des coefficients estimés sont plus petits dans l'ensemble de test. Pour les modèles ARMA(1,1) et ARMA(1,2), on remarque le contraire, les écarts types sont plus bas dans l'ensemble d'entraînement.

7. Tests diagnostics

7.1 Calcul de l'AIC et BIC

Échantillon d'entraînement:

Série ipc_haei:	AIC	BIC
Modèle simple	-1314.643	-1303.675
Modèle imbriqué	-1314.188	-1303.675

Comparaison et discussion: on voit que arma(0,0,1) a les plus petits aic et bic, donc il est meilleur.

Série ipc_global	AIC	BIC
Modèle simple	-997.7086	-979.4287
Modèle imbriqué	-999.6679	-985.044

Comparaison et discussion: on voit qu'ARMA(1,0,2) a les plus petits AIC et BIC, donc il est meilleur.

Échantillon de test:

Série ipc_haei:	AIC	BIC

Modèle simple	-280.2087	-273.4206
Modèle imbriqué	-277.4166	-268.3659

Comparaison et discussion: on voit qu'ARMA(0,0,1) a les plus petits AIC et BIC, donc il est meilleur.

Série ipc_global	AIC	BIC
Modèle simple	-219.5119	-208.1985
Modèle imbriqué	-220.1421	-211.0914

Comparaison et discussion: on voit qu 'Arma(1,0,2) a les plus petits AIC et BIC, donc il est meilleur.

2

0

7.2 Calcul de la statistique du ratio de vraisemblance et de la valeur-p

$\Lambda = -2(\ell_{\text{restreint}} - \ell_{\text{non restreint}})$
$\Lambda \sim \chi^2$,
avec $\Lambda = \ell_{\text{restreint}} - \ell_{\text{non restreint}}$

Pour l'échantillon d'entrainement:

Pour la série ipc_haei:

Après avoir fait le calcul dans r, on obtient le ratio de vraisemblance qui égal à 1.5452 et la valeur-p qui est 0.2138. Elle a une valeur-p qui est très supérieure à 5%

Pour la série ipc_global:

Après avoir fait le calcul dans r, on obtient le ratio de vraisemblance qui égal à 0.0407 et la valeur-p qui est 0.8401.Elle a une valeur-p qui est très supérieure à 5%

Pour les deux cas, le ratio de vraisemblance nous dit que le modèle le plus approprié est le modèle le plus simple d'où le modèle MA(1) pour l'IPC-HAEI et MA(2) pour l'IPC-GLOBAL.

Pour l'échantillon de test:

Pour la série ipc_haei:

Après avoir fait le calcul dans r, on obtient le ratio de vraisemblance qui égal à 0.7921 et la valeur-p qui est 0.3735.Elle a une valeur-p qui est très supérieure à 5%

Pour la série ipc_global:

Après avoir fait le calcul dans r, on obtient le ratio de vraisemblance qui égal à 1.3699 et la valeur-p qui est 0.2418.Elle a une valeur-p qui est très supérieure à 5%.

Pour les deux cas, le ratio de vraisemblance nous dit que le modèle le plus approprié est le modèle le plus simple d'où le modèle MA(1) pour l'IPC-HAEI et MA(2) pour l'IPC-GLOBAL.

7.3 Calcul des valeurs ajustées, de l'erreur quadratique moyenne

Série ipc_global:

Dans l'échantillon dans l'ensemble d'entraînement.

Valeur ajustée:

```
val_ajust1 <- fitted(modèle1_ipc_global)
val_ajust2 <- fitted(modèle2_ipc_global)
```

Erreur quadratique moyenne:

```
erreur_entrainement1 : 6.354591e-05
erreur_entrainement2 : 5.477015e-05
```

L'erreur quadratique du modèle imbriqué MA(2) est inférieure à celle du premier modèle ARMA(1,2). Cela nous indique que le modèle le plus simple minimise les erreurs.

Hors échantillon sur l'ensemble de test.

Prédiction:

Erreur quadratique moyenne:


```
erreur_test1: 0.05317547
erreur_test2: 0.05317391
```

L'erreur quadratique du modèle imbriqué MA(2) est sensiblement pareille à celle du premier modèle ARMA(1,2).

Série ipc_haei:

Dans l'échantillon dans l'ensemble d'entraînement.

Valeur ajustée:

```
val_ajust3 <- fitted(modèle1_ipc_haei)

val_ajust4 <- fitted(modèle2_ipc_haei)
```

Erreur quadratique moyenne :

```
erreur_entrainement1 : 1.632253e-06
erreur_entrainement2 : 8.019162e-06
```

L'erreur quadratique du premier modèle MA(1) est inférieure à celle du modèle ARMA(1,1).

Hors échantillon sur l'ensemble de test.

Prédiction:

Erreur quadratique moyenne:

```
erreur_test1: 0.03243576
erreur_test2 : 0.03243576
```

L’erreur quadratique des deux modèles est pareille.

Le modèle qu’on recommanderait serait le modèle le MA(1) pour l’IPC-HAEI et MA(2) pour l’IPC-GLOBAL.

8. Modèle bivarié et corrélations croisées

8.1 Analyse des propriétés statistiques

Dans cette section, nous analysons les propriétés statistiques des innovations extraites des modèles ARMA ajustés respectivement aux séries de l’IPC global et de l’IPC haei au Canada, couvrant la période de 1995 à 2024. Les innovations représentent la composante aléatoire résiduelle, c’est-à-dire la part de la dynamique des séries qui n’est pas expliquée par les composantes autorégressives et de moyenne mobile des modèles. L’objectif est de vérifier si les hypothèses classiques sur ces résidus sont respectées, à savoir : une moyenne nulle (absence de biais systématique), une variance constante (homoscédasticité), et une absence d’autocorrélation significative (bruit blanc). La validité de ces hypothèses est essentielle pour garantir la qualité de l’ajustement, la fiabilité des prévisions, ainsi que la pertinence économique des conclusions tirées à partir des modèles estimés.

<u>IPC -global</u>

Moyenne des innovations

L’analyse de la moyenne des innovations permet de vérifier si les résidus du modèle sont centrés autour de zéro, condition essentielle pour qu’ils puissent être considérés comme un bruit blanc. Dans notre cas, la moyenne des innovations est estimée à 0.00016. Cette valeur très proche de zéro indique que les erreurs du modèle ne présentent pas de biais systématique et qu’elles s’annulent en moyenne.

Variance des innovations

La variance des innovations est un indicateur clé de la dispersion des résidus autour de leur moyenne. Dans cette analyse, la variance obtenue est d’environ 0.00232. Cette valeur modérée témoigne d’une bonne qualité d’ajustement : les innovations, bien que présentes, demeurent d’amplitude réduite, ce qui signifie que le modèle parvient à expliquer une grande partie de la variation de la série temporelle. Une faible variance des erreurs est généralement souhaitable, car elle suggère que peu d’information significative a échappé au modèle.

Autocorrélation des innovations

Les autocorrélations devraient être proches de zéro si les innovations suivent bien un bruit blanc (i.e. aucune structure temporelle restante). Or, nous observons :

- Des valeurs relativement élevées aux lags 3, 5, 8, 19, et 20.
- Certaines autocorrélations dépassent potentiellement les bornes de significativité statistique (≈ ±0.14 pour n ≈ 200).

<u>IPC-HAEI</u>

Moyenne des innovations

La moyenne des innovations obtenues à partir du modèle ARMA appliqué à la série IPC-HAEI est de 0.00051. Cette valeur, bien que légèrement plus élevée que celle observée pour l'IPC global, demeure très proche de zéro. Cela indique que les résidus sont en moyenne bien centrés, ce qui est conforme à l'hypothèse d'absence de biais systématique. Autrement dit, le modèle ne laisse pas de tendance prévisible non captée dans les erreurs, ce qui renforce la validité statistique de l'estimation pour cette composante de l'IPC.

Variance des innovations

La variance estimée des innovations s'élève à 0.00103, une valeur légèrement inférieure à celle observée pour l'IPC global. Cela suggère que les erreurs du modèle, bien que présentes, sont relativement contenues et que la majeure partie de la variabilité de la série IPC-HAEI est bien modélisée. Une variance modérée des résidus est souhaitable, car elle indique une bonne capacité du modèle à expliquer les fluctuations de la série à travers ses composantes autorégressives et de moyenne mobile.

Autocorrélation des innovations

Les autocorrélations devraient être proches de zéro si les innovations suivent bien un bruit blanc, c'est-à-dire si aucune structure temporelle ne subsiste dans les résidus. Or, plusieurs valeurs dépassent des seuils habituellement considérés comme statistiquement significatifs (±0.14 pour un échantillon d'environ 200 observations), notamment :

● Au lag 3 (0.217), au lag 4 (0.156), au lag 6 (0.165), au lag 8 (0.147), au lag 9 (0.151), au lag 11 (0.166), au lag 13 (-0.289) et au lag 20 (-0.145).

8.2 Calcul et représentation graphique de la fonction de corrélation (CCF). 24

Après ajustement d'un modèle ARMA(p,q) à chacune d'elles. On a que :

Le pic à lag 0 est nettement significatif et positif (environ 0.5), ce qui indique une corrélation

immédiate forte entre les innovations des deux séries. Cela peut signaler qu'il existe un lien entre l'innovation haei et l'innovation globale.
Les autres lags comme celui du lag 10 semblent aussi être significatifs, suggérant des retards dans l'influence d'une série sur l'autre.
L'asymétrie autour de 0 (les barres significatives du côté positif des lags et ceux du côté négatif) indique une possible causalité, car pour les lags positifs cela peut suggérer que des innovations dans haei affecteraient global avec un délai.

8.3 Test des résidus

Afin de vérifier si les résidus (ou innovations) des deux séries l'IPC-GLOBAL et l'IPC-HAEI sont statistiquement indépendants, nous avons effectué un test de Ljung-Box sur la fonction de corrélation croisée (CCF) des deux séries résiduelles. Ce test permet de détecter la présence éventuelle de dépendance entre les résidus à différents décalages temporels (lags).

Le test a été réalisé avec un maximum de 10 retards. Le résultat du test est le suivant :

La statistique de test est de 5.1524 avec 10 degrés de liberté, et la valeur p associée est de 0.8808. Cette valeur p, étant bien supérieure au seuil classique de 0.05, indique que nous ne pouvons pas rejeter l'hypothèse nulle d'absence de corrélation croisée.

Nous en concluons donc que les résidus des deux modèles ARMA sont statistiquement non corrélés. Autrement dit, les innovations de l'IPC-GLOBAL et celles de l'IPC-HAEI sont indépendantes une fois les dynamiques propres à chaque série modélisées, ce qui renforce la qualité de l'ajustement des deux modèles.

8.4 Explication des hypothèses

Le modèle ARMA bivarié, aussi appelé ARMA(□□, □□) , est une extension du modèle ARMA au cadre multivarié. Il permet de modéliser simultanément deux séries temporelles corrélées, en tenant compte non seulement de leur dynamique propre, mais aussi de leurs interactions.

Hypothèses sous-jacentes au modèle ARMA bivarié :

1. Stationnarité conjointe des séries :
   Les deux séries doivent être stationnaires, c'est-à-dire que leurs propriétés statistiques (moyenne, variance, autocorrélation) ne changent pas dans le temps. Si ce n'est pas le cas, elles doivent être rendues stationnaires par transformation (différenciation, logarithme, etc.).

2. Relations dynamiques croisées :
   Chaque série est influencée non seulement par ses propres valeurs passées (comme dans un ARMA classique), mais aussi par les valeurs passées de l'autre série. Par exemple, l'évolution de l'IPC haei peut dépendre de celle de l'IPC global, et réciproquement.

3. Erreurs corrélées :
   Contrairement à la modélisation univariée, le modèle ARMA bivarié autorise une corrélation contemporaine (instantanée) entre les erreurs des deux équations. Cela reflète l'existence possible de chocs communs qui affectent simultanément les deux séries.

4. Structure matricielle des coefficients :
   Les coefficients autorégressifs et de moyenne mobile sont représentés sous forme de matrices, ce qui permet de modéliser les interactions croisées et internes entre les deux séries.

Différences avec une modélisation séparée :

Dans une modélisation séparée, chaque série est traitée indépendamment à l'aide de son propre modèle ARMA. Aucune information sur l'autre série n'est utilisée : les coefficients, les innovations et les dynamiques sont estimés séparément. Cette approche suppose implicitement que les deux séries sont indépendantes dans le temps, ce qui peut conduire à une perte d'information si ce n'est pas le cas.

En revanche, dans un modèle ARMA bivarié, les deux séries sont modélisées conjointement, ce qui permet de capter les corrélations croisées, les effets de rétroaction et les dynamiques communes. Cela permet une modélisation plus réaliste lorsque les séries présentent des interdépendances économiques ou structurelles, comme c'est souvent le cas entre deux composantes de l'IPC.

<u>En conclusion</u> :

Un modèle ARMA bivarié repose sur des hypothèses plus riches que la modélisation séparée : il tient compte de la structure conjointe des erreurs, des interactions dynamiques entre séries, et permet une représentation plus fidèle de phénomènes économiques liés. Il est particulièrement pertinent lorsque les séries partagent des sources de variation communes ou lorsqu'un effet causal bidirectionnel est soupçonné. En revanche, il nécessite plus de données et une estimation plus complexe.

Références

Brockwell, P. J., & Davis, R. A. (Eds.). (2002). Introduction to time series and forecasting. New York, NY: Springer New York.

Banque du Canada. (2024). Indice des prix à la consommation tronqué (IPC GLOBAL) (Série v41690973, fréquence mensuelle). Banque du Canada. Consulté le 01 mars 2025, à partir de https://www.banqueducanada.ca/

Banque du Canada. (2024). Indice des prix à la consommation tronqué (IPC-HAEI) (Série v41755376, fréquence mensuelle). Banque du Canada.

Consulté le 01 mars 2025, à partir de https://www.banqueducanada.ca/

ANNEXE

Codes

#Partie 1

#Description des données.

```
sum(is.na(donnees2))
```

```
ipc_haei <- ts(donnees2$ipc_haei,
               start = c(1995, 1),
               frequency = 12)
ipc_global <- ts(donnees2$ipc_global,
               start = c(1995, 1),
               frequency = 12)

summaryipc_haei <- data.frame(
  Statistique = c("Minimum", "1er Quartile", "Médiane", "Moyenne", "3ème
Quartile", "Maximum", "Écart-type"),
  Valeur = c(round(min(ipc_haei),2),
             round(quantile(ipc_haei, 0.25),2),
             round(median(ipc_haei),2),
             round(mean(ipc_haei),2),
             round(quantile(ipc_haei, 0.75),2),
             round(max(ipc_haei),2),
             round(sd(ipc_haei),2))
)
data.frame(summaryipc_haei)


summaryipc_global <- data.frame(
  Statistique = c("Minimum", "1er Quartile", "Médiane", "Moyenne", "3ème
Quartile", "Maximum", "Écart-type"),
  Valeur = c(round(min(ipc_global),2),
             round(quantile(ipc_global, 0.25),2),
             round(median(ipc_global),2),
             round(mean(ipc_global),2),
             round(quantile(ipc_global, 0.75),2),
             round(max(ipc_global),2),
             round(sd(ipc_global),2))
)
data.frame(summaryipc_global)

donnees2$Dates <- as.Date(donnees2$Dates, format = "%Y-%m-%d")
ggplot(donnees2, aes(x = Dates, y = ipc_haei)) +
  geom_line(color = "black", size = 1) +
  labs(
    title = "IPC-haei au Canada, données mensuelles",
    x = "Dates",
    y = "Indice en %"
  ) +
  theme_minimal() +
  scale_x_date(date_labels = "%Y", date_breaks = "2 years")


ggplot(donnees2, aes(x = Dates, y = ipc_global)) +
  geom_line(color = "black", size = 1) +
  labs(
```

```
    title = "IPC-global au Canada, données mensuelles",
    x = "Dates",
```



```
    y = "Indice en %"
  ) +
  theme_minimal() +
  scale_x_date(date_labels = "%Y", date_breaks = "2 years")
```

#Filtrage de nos séries.

#Application du lissage linéaire. #ipc_haei.

```
lissage_lineaire <- function(X, q) {
  N <- length(X)
  poids <- 1 / (2 * q + 1)
  indices <- (q+1):(N-q)
  X_filt <- rep(NA, N)
  for (i in indices) {
    X_filt[i] <- sum(X[(i-q):(i+q)] * poids)
  }
  return(X_filt)
}


q1 <- 2
q2 <- 12
ipc_haei_lissageq1 <- lissage_lineaire(ipc_haei,q1)
ipc_haei_lissageq2 <- lissage_lineaire(ipc_haei,q2)



mse <- function(original, lisse) {
  valid_indices <- which(!is.na(lisse))
  mean((original[valid_indices] - lisse[valid_indices])^2)
}

# Supprimer les NA avant le calcul
valid_indices1 <- which(!is.na(ipc_haei_lissageq1))
valid_indices2 <- which(!is.na(ipc_haei_lissageq2))

mse_q1 <- mse(ipc_haei, ipc_haei_lissageq1)
mse_q2 <- mse(ipc_haei, ipc_haei_lissageq2)

print(paste("MSE pour q1=2 (ipc_haei) :", mse_q1))

print(paste("MSE pour q2=12 (ipc_haei) :", mse_q2))
```

#ipc_global.

```
lissage_lineaire <- function(X, q) {
  N <- length(X)
```

```
  poids <- 1 / (2 * q + 1)
  indices <- (q+1):(N-q)
  X_filt <- rep(NA, N)
  for (i in indices) {
```



```
    X_filt[i] <- sum(X[(i-q):(i+q)] * poids)
  }
  return(X_filt)
}

q1 <- 2
q2 <- 12
ipc_global_lissageq1 <- lissage_lineaire(ipc_global,q1)
ipc_global_lissageq2 <- lissage_lineaire(ipc_global,q2)

mse <- function(original, lisse) {
  valid_indices <- which(!is.na(lisse))
  mean((original[valid_indices] - lisse[valid_indices])^2)
}

# Supprimer les NA avant le calcul
valid_indices1 <- which(!is.na(ipc_global_lissageq1))
valid_indices2 <- which(!is.na(ipc_global_lissageq2))

mse_q11 <- mse(ipc_global, ipc_global_lissageq1)
mse_q22 <- mse(ipc_global, ipc_global_lissageq2)

print(paste("MSE pour q1=2 (ipc_global) :", mse_q11))

print(paste("MSE pour q2=12 (ipc_global) :", mse_q22))
```

#Application du lissage exponentiel. #ipc_haei.

```
lissage_exponentiel <- function(X, alpha) {
  N <- length(X)
  X_filt <- numeric(N)
   X_filt[1] <- X[1] # La première valeur est égale à la donnée d'origine

  # Appliquer le lissage exponentiel
  for (i in 2:N) {
    X_filt[i] <- alpha * X[i] + (1 - alpha) * X_filt[i - 1]
  }
  return(X_filt)
}

# Application du lissage exponentiel sur les données

alpha1 <- 0.1
alpha2 <- 0.5
alpha3 <- 0.9

ipc_haei_lissagea1 <- lissage_exponentiel(ipc_haei, alpha1)
```

```r
ipc_haei_lissagea2 <- lissage_exponentiel(ipc_haei, alpha2)
ipc_haei_lissagea3 <- lissage_exponentiel(ipc_haei, alpha3)

mse <- function(original, lisse) {
  mean((original - lisse)^2)
}
```



```r
# Calcule du MSE pour chaque alpha sur ipc_haei
mse_alpha1 <- mse(ipc_haei, ipc_haei_lissagea1)
mse_alpha2 <- mse(ipc_haei, ipc_haei_lissagea2)
mse_alpha3 <- mse(ipc_haei, ipc_haei_lissagea3)

# Afficher les résultats
print(paste("MSE pour alpha=0.1 (ipc_haei) :", mse_alpha1))

print(paste("MSE pour alpha=0.5 (ipc_haei) :", mse_alpha2))

print(paste("MSE pour alpha=0.9 (ipc_haei) :", mse_alpha3))
```

#ipc_global.

```r
lissage_exponentiel <- function(X, alpha) {
  N <- length(X)
  X_filt <- numeric(N)
   X_filt[1] <- X[1] # La première valeur est égale à la donnée d'origine

  # Appliquer le lissage exponentiel
  for (i in 2:N) {
    X_filt[i] <- alpha * X[i] + (1 - alpha) * X_filt[i - 1]
  }
  return(X_filt)
}

# Application du lissage exponentiel sur les données


alpha1 <- 0.1
alpha2 <- 0.5
alpha3 <- 0.9

ipc_global_lissagea1 <- lissage_exponentiel(ipc_global, alpha1)
ipc_global_lissagea2 <- lissage_exponentiel(ipc_global, alpha2)
ipc_global_lissagea3 <- lissage_exponentiel(ipc_global, alpha3)



mse <- function(original, lisse) {
  mean((original - lisse)^2)
}
mse_alpha1_ipc_global <- mse(donnees2$ipc_global, ipc_global_lissagea1)
mse_alpha2_ipc_global <- mse(donnees2$ipc_global, ipc_global_lissagea2)
mse_alpha3_ipc_global <- mse(donnees2$ipc_global, ipc_global_lissagea3)
```

```r
# Afficher les résultats
print(paste("MSE pour alpha=0.1 (ipc_global):", mse_alpha1_ipc_global))

print(paste("MSE pour alpha=0.5 (ipc_global):", mse_alpha2_ipc_global))

print(paste("MSE pour alpha=0.9 (ipc_global):", mse_alpha3_ipc_global))
```


Illustrons nos séries filtrées.

```r
#ipc_haei LN

# Configuration de la fenêtre graphique
par(mfrow = c(1, 1)) # Affiche un seul graphique

# Graphique de ipc_haei avec les dates sur l'axe des X
plot(donnees2$Dates, ipc_haei, type = 'l', xlab = 'Dates', ylab =
 'ipc_haei',
     main = 'Série de ipc_haei filtrée par le lissage linéaire')

# Ajouter les lignes filtrées
lines(donnees2$Dates, ipc_haei_lissageq1, col = 'red')
lines(donnees2$Dates, ipc_haei_lissageq2, col = 'blue')

# Ajouter une ligne horizontale à 0
abline(h = 0, col = 'black', lty = 2)


legend("topleft", legend = c(expression(ipc_haei[n]),
                             expression("q=2"),
                             expression("q=12")),
       col = c('black', 'red', 'blue'), lty = 1, bty = "n")


#ipc_haei EXP
par(mfrow = c(1, 1))
plot(donnees2$Dates, ipc_haei, type = 'l',col = 'black', xlab = 'Dates',
ylab = 'ipc_haei',
     main = 'Série de ipc_haei filtrée par lissage exponentiel')
lines(donnees2$Dates,ipc_haei_lissagea1 , col = 'green')
lines(donnees2$Dates, ipc_haei_lissagea2 , col = 'red')
lines(donnees2$Dates,ipc_haei_lissagea3 , col = 'blue')
abline(h = 0, col = 'black', lty = 2)


legend("topleft", legend = c(expression(ipc_haei[n]),
                             expression(paste(alpha,"=0.1")),
                             expression(paste(alpha,"=0.5")),
                             expression(paste(alpha,"=0.9"))),
       col = c('black','green','red','blue'), lty = 1, bty = "n")
```

```r
#ipc_global LIN
par(mfrow = c(1, 1))
plot(donnees2$Dates, ipc_global ,type = 'l', xlab = 'Dates',ylab =
'ipc_global',main = 'Série de ipc_global filtrée par lissage
lineaire')

lines(donnees2$Dates,ipc_global_lissageq1, col = 'red')
lines(donnees2$Dates,ipc_global_lissageq2 , col = 'blue') 33



abline(h = 0, col = 'black', lty = 2)

legend("topleft", legend = c(expression(ipc_global[n]),
                             expression("q=2"),
                              expression("q=12")),
       col = c('black','red', 'blue'), lty = 1, bty = "n")


#ipc_global EXP
par(mfrow = c(1, 1))
plot(donnees2$Dates,ipc_global, type = 'l', col = 'black', xlab = 'Dates',
ylab = 'ipc_global', main = 'Série de ipc_global filtrée par lissage
exponentiel')
lines(donnees2$Dates, ipc_global_lissagea1 , col = 'green')
lines(donnees2$Dates, ipc_global_lissagea2 , col = 'red')
lines(donnees2$Dates, ipc_global_lissagea3 , col = 'blue')
abline(h = 0, col = 'black', lty = 2)

# Ajouter une légende
legend("topleft", legend = c(expression(ipc_global[n]),
                             expression(paste(alpha,"=0.1")),
                             expression(paste(alpha,"=0.5")),
                             expression(paste(alpha,"=0.9"))),
       col = c('black','green','red','blue'), lty = 1, bty = "n")
```

Soustrayons les valeurs filtrées des séries chronologiques et illustrons les.

```r
#ipc_haei LIN
# Supprimer les valeurs NA avant le calcule des résidus
valid_indices1 <- which(!is.na(ipc_haei_lissageq1))

resid_lisq1_ipc_haei <- ipc_haei[valid_indices1] -
ipc_haei_lissageq1[valid_indices1]

# Calcule de la moyenne et la variance des résidus
cat("moyenne des résidus est",mean(resid_lisq1_ipc_haei),"et la variance
```

```
est",var(resid_lisq1_ipc_haei),"\n")
```

```
## moyenne des résidus est 0.0009065156 et la variance est 0.02709236
```

```
par(mfrow = c(1, 1))
plot(resid_lisq1_ipc_haei, type = 'l', col = 'red', main = "Résidus
ipc_haei - Lissage Linéaire (q=2)", ylab = "Résidus", xlab = "Temps")
abline(h = 0, col = 'black', lty = 2)
```



```
#ipc_haei EXP
valid_indices5 <- which(!is.na(ipc_haei_lissagea3))
resid_lisa3_ipc_haei <- ipc_haei[valid_indices5] -
ipc_haei_lissagea3[valid_indices5]

# Calcule de la moyenne et de la variance des résidus
cat("moyenne des résidus est",mean(resid_lisa3_ipc_haei),"et la variance
est",var(resid_lisa3_ipc_haei),"\n")
```

```
## moyenne des résidus est 6.324251e-05 et la variance est 0.0006786182
```

```
# Tracer les résidus pour le lissage exponentiel
par(mfrow = c(1, 1))
plot(resid_lisa3_ipc_haei, type = 'l', col = 'blue', main = "Résidus
ipc_haei- Lissage Exponentiel (alpha=0.9)", ylab = "Résidus", xlab =
"Temps")
abline(h = 0, col = 'black', lty = 2)
```

```
#ipc_global LIN

valid_indices22 <- which(!is.na(ipc_global_lissageq1))


resid_lisq1_ipc_global <- ipc_global[valid_indices22] -
ipc_global_lissageq1[valid_indices22]

# Calcule de la moyenne et la variance des résidus
cat("moyenne des résidus est",mean(resid_lisq1_ipc_global),"et la variance
est",var(resid_lisq1_ipc_global),"\n")
```

```
## moyenne des résidus est 0.002492918 et la variance est 0.08232331
```

```
par(mfrow = c(1, 1))
plot(resid_lisq1_ipc_global, type = 'l', col = 'blue', main = "Résidus
ipc_global - Lissage Linéaire (q=2)", ylab = "Résidus", xlab = "Temps")
abline(h = 0, col = 'black', lty = 2)
```

```r
#ipc_global EXP
valid_indices55 <- which(!is.na(ipc_global_lissagea3))

resid_lisa3_ipc_global<- ipc_global[valid_indices55] -
ipc_global_lissagea3[valid_indices55]

# Calcule de la moyenne et de la variance des résidus
cat("moyenne des résidus est",mean(resid_lisa3_ipc_global),"et la variance
est",var(resid_lisa3_ipc_global),"\n")
```

```
## moyenne des résidus est 0.0003253091 et la variance est 0.002025637
```

```r
# Tracer les résidus pour le lissage exponentiel
```



```r
plot(resid_lisa3_ipc_global, type = 'l', col = 'blue', main = "Résidus
ipc_global- Lissage Exponentiel (alpha=0.9)", ylab = "Résidus", xlab =
"Temps")
abline(h = 0, col = 'black', lty = 2)
```

#Vérifions la stationnarité. #Application du test ADF sur les résidus obtenus.

```r
#résidus staionnaire <0.05
adf_manual_test <- function(series) {
  n <- length(series)
  # Construction des variables pour la régression
  delta_series <- diff(series) # Différence première
  Y_lag <- series[-n] # Décalage de la série (Y_{t-1})

  # Régression : ΔY_t ~ Y_{t-1}
  regression <- lm(delta_series ~ Y_lag)

  # Extraction de la statistique de test (t-value du coefficient de
Y_{t-1})
  t_stat <- summary(regression)$coefficients[2, 3] # t-value

  # Valeurs critiques de Dickey-Fuller pour un échantillon de taille
modérée (~100 obs)
  critical_values <- c(-3.50, -2.89, -2.58) # 1%, 5%, 10%

  # Conclusion du test
  cat("Statistique de test ADF :", t_stat, "\n")
  cat("Valeurs critiques (1% | 5% | 10%) :", critical_values, "\n")

  if (t_stat < critical_values[2]) {
    cat(" Hypothèse de non-stationnarité rejetée (stationnaire à 5%)\n") }
  else {
    cat(" Hypothèse de non-stationnarité non rejetée (série non
stationnaire)\n")
  }
```

```
}
adf_manual_test(resid_lisq1_ipc_haei)

adf_manual_test(resid_lisa3_ipc_haei)

adf_manual_test(resid_lisq1_ipc_global)


adf_manual_test(resid_lisa3_ipc_global)
```

Les séries résiduelles sont stationnaires avec le test ADF.

#Application du test ADF LJUNG BOX.

```
#LJUNG BOX
h <- 6
```



```
Box.test(resid_lisq1_ipc_haei, lag = h, type = "Ljung-Box")

Box.test(resid_lisa3_ipc_haei, lag = h, type = "Ljung-Box")

Box.test(resid_lisq1_ipc_global, lag = h, type = "Ljung-Box")

Box.test(resid_lisa3_ipc_global, lag = h, type = "Ljung-Box")
```

#Application du test McLeod-Lee.

```
# McLeod-Lee
Box.test(resid_lisq1_ipc_haei^2, lag = h, type = "Ljung-Box")



Box.test(resid_lisa3_ipc_haei^2, lag = h, type = "Ljung-Box")


Box.test(resid_lisq1_ipc_global^2, lag = h, type = "Ljung-Box")


Box.test(resid_lisa3_ipc_global^2, lag = h, type = "Ljung-Box")
```

#Différentiation de nos séries.

#Appliquons la différenciation sur nos séries.

```
#ipc_haei
# Différenciation d'ordre 1
diff1_ipc_haei <- diff(ipc_haei)
```

```
plot(donnees2$Dates[-c(1)], diff1_ipc_haei, type="l", col="red",
main="Différenciation
     d'ordre 1 pour ipc_haei ", xlab="Données", ylab="Périodes")
```

```
#ipc_global
# Différenciation d'ordre 1
diff1_ipc_global <- diff(ipc_global)
plot(donnees2$Dates[-c(1) ], diff1_ipc_global, type="l", col="green",
main="Différenciation
d'ordre 1 pour ipc_global", xlab="Données", ylab="Périodes")
```

#Illustrons les séries différentiées et calculons la moyenne et la variance.

```
#ipc_haei
Moy_IPC_haei <- mean(diff1_ipc_haei)
Var_IPC_haei <- var(diff1_ipc_haei)

#ipc_global
Moy_IPC_global <- mean(diff1_ipc_global)
```



```
Var_IPC_global <- var(diff1_ipc_global)

cat("Pour l'IPC_haei, la moyenne est",Moy_IPC_haei,"et la variance
est",Var_IPC_haei,"\n")


cat("Pour l'IPC_global, la moyenne est",Moy_IPC_global,"et la variance
est",Var_IPC_global,"\n")
```

#Testons la stationnarité. #Appliquons le test de ADF.

```
adf_manual_test(diff1_ipc_global)


adf_manual_test(diff1_ipc_haei)
```

#Appliquons le test de Box-Pierce.

```
h <- 6
# Tests
Box.test(diff1_ipc_haei, lag = h, type = "Box-Pierce")


Box.test(diff1_ipc_global, lag = h, type = "Box-Pierce")
```

#Stationnarité

#Nous allons utiliser le lissage exponentiel pour obtenir des séries de moyennes constantes.

```
#FONCTION D'AUTOCORRELATION
autocorr <- function(X, hmax){
N <- length(X)
hmax <- min(hmax,N-1)
autocorr <- rep(0,hmax + 1)
for(h in 0:hmax){
autocorr[h+1] <- cor(X[1:(N-h)],X[(h+1):N])
}
return(autocorr)
}
acf_ipcglobal <- autocorr(resid_lisa3_ipc_global, 20)
#Figures
par(mfrow = c(1, 1))
plot(acf_ipcglobal, main = 'Autocorrélation ipc_global', xlab = 'h', ylab
= expression(paste(gamma),"(h)"),
ylim = c(-1,1))
abline(h = 0, col = 'black', lty = 2)
```



```
acf_ipchaei <- autocorr(resid_lisa3_ipc_haei, 20)
#Figures
par(mfrow = c(1, 1))
plot(acf_ipchaei, main = 'Autocorrélation ipc_haei', xlab = 'h', ylab =
expression(paste(gamma),"(h)"),
ylim = c(-1,1))
abline(h = 0, col = 'black', lty = 2)
```

#Partie 2

#Sélection des ordres des modeles ARMA

#Appliquons ACF ET PACF sur ipc_haei

```
#ACF ipc_haei
n <- length(resid_lisa3_ipc_haei)
acf_values <- acf(resid_lisa3_ipc_haei, plot = FALSE, lag.max = 20)$acf
acf_values <- acf_values[1:20]
lags <- 1:20

# Calcul des intervalles de confiance
alpha_levels <- c(0.9, 0.95, 0.99)
z_vals <- qnorm(1 - (1 - alpha_levels) / 2)
ICs <- lapply(z_vals, function(z) z / sqrt(n))
```

```r
# Affichage
df <- data.frame(
  lag = rep(lags, times = 3),
  acf = rep(acf_values, times = 3),
  alpha = factor(rep(c("90%", "95%", "99%"), each = 20)),
  IC = c(rep(ICs[[1]], 20), rep(ICs[[2]], 20), rep(ICs[[3]], 20))
)
ggplot(df, aes(x = lag, y = acf)) +
  geom_hline(yintercept = 0, color = "black") +
  geom_segment(aes(xend = lag, yend = 0), color = "blue") +
geom_hline(aes(yintercept = IC, color = alpha), linetype = "dashed") +
geom_hline(aes(yintercept = -IC, color = alpha), linetype = "dashed") +
scale_color_manual(values = c("green", "blue", "red")) + labs(title =
"ACF ipc_haei avec IC à 90%, 95% et 99%", y = "ACF", color = "Niveau de
confiance") +
  theme_minimal()


n <- length(resid_lisa3_ipc_haei)
alpha_levels <- c(0.90, 0.95, 0.99)
z_vals <- qnorm(1 - (1 - alpha_levels) / 2)
ICs <- round(z_vals / sqrt(n), 4)

# Affichage sous forme de tableau
data.frame(
```



```r
  "Niveau de confiance" = paste0(alpha_levels * 100,
  "%"), "Borne inférieure" = -ICs,
  "Borne supérieure" = ICs
)


#PACF ipc_haei
n <- length(resid_lisa3_ipc_haei)
pacf_values <- pacf(resid_lisa3_ipc_haei, plot = FALSE, lag.max = 20)$acf
lags <- 1:20

# Niveaux de confiance
alpha_levels <- c(0.9, 0.95, 0.99)
z_vals <- qnorm(1 - (1 - alpha_levels) / 2)
ICs <- lapply(z_vals, function(z) z / sqrt(n))

# Préparation du tableau pour ggplot
library(ggplot2)

df_pacf <- data.frame(
  lag = rep(lags, times = 3),
  pacf = rep(pacf_values, times = 3),
  alpha = factor(rep(c("90%", "95%", "99%"), each = 20)),
```

```
  IC = c(rep(ICs[[1]], 20), rep(ICs[[2]], 20), rep(ICs[[3]], 20))
)

# Tracé du graphique PACF avec IC multiples
ggplot(df_pacf, aes(x = lag, y = pacf)) +
  geom_hline(yintercept = 0, color = "black") +
  geom_segment(aes(xend = lag, yend = 0), color = "blue") +
geom_hline(aes(yintercept = IC, color = alpha), linetype = "dashed") +
geom_hline(aes(yintercept = -IC, color = alpha), linetype = "dashed") +
scale_color_manual(values = c("green", "blue", "red")) + labs(title =
"PACF ipc_haei avec IC à 90%, 95% et 99%", y = "PACF", color = "Niveau de
confiance") +
  theme_minimal()


ICs_pacf <- round(z_vals / sqrt(n), 4)

data.frame(
  "Niveau de confiance" = paste0(alpha_levels * 100,
  "%"), "Borne inférieure" = -ICs_pacf,
  "Borne supérieure" = ICs_pacf
)
```

#Appliquons ACF ET PACF sur ipc_global

```
#ACF ipc_global
n <- length(resid_lisa3_ipc_global)
```



```
acf_values <- acf(resid_lisa3_ipc_global, plot = FALSE, lag.max = 20)$acf
acf_values <- acf_values[1:20]
lags <- 1:20

# Calcul des intervalles de confiance
alpha_levels <- c(0.9, 0.95, 0.99)
z_vals <- qnorm(1 - (1 - alpha_levels) / 2)
ICs <- lapply(z_vals, function(z) z / sqrt(n))

# Affichage

df <- data.frame(
  lag = rep(lags, times = 3),
  acf = rep(acf_values, times = 3),
  alpha = factor(rep(c("90%", "95%", "99%"), each = 20)),
  IC = c(rep(ICs[[1]], 20), rep(ICs[[2]], 20), rep(ICs[[3]], 20))
)
ggplot(df, aes(x = lag, y = acf)) +
  geom_hline(yintercept = 0, color = "black") +
  geom_segment(aes(xend = lag, yend = 0), color = "blue") +
geom_hline(aes(yintercept = IC, color = alpha), linetype = "dashed") +
```

```r
geom_hline(aes(yintercept = -IC, color = alpha), linetype = "dashed") +
scale_color_manual(values = c("green", "blue", "red")) + labs(title =
"ACF ipc_global avec IC à 90%, 95% et 99%", y = "ACF", color = "Niveau de
confiance") +
  theme_minimal()


n <- length(resid_lisa3_ipc_global)
alpha_levels <- c(0.90, 0.95, 0.99)
z_vals <- qnorm(1 - (1 - alpha_levels) / 2)
ICs <- round(z_vals / sqrt(n), 4)

# Affichage sous forme de tableau
data.frame(
  "Niveau de confiance" = paste0(alpha_levels * 100,
  "%"), "Borne inférieure" = -ICs,
  "Borne supérieure" = ICs
)

#PACF ipc_global
n <- length(resid_lisa3_ipc_global)
pacf_values <- pacf(resid_lisa3_ipc_global, plot = FALSE, lag.max =
20)$acf
lags <- 1:20

# Niveaux de confiance
alpha_levels <- c(0.9, 0.95, 0.99)
z_vals <- qnorm(1 - (1 - alpha_levels) / 2)
ICs <- lapply(z_vals, function(z) z / sqrt(n))

# Préparation du tableau pour ggplot
library(ggplot2)
```



```r
df_pacf <- data.frame(
  lag = rep(lags, times = 3),
  pacf = rep(pacf_values, times = 3),
  alpha = factor(rep(c("90%", "95%", "99%"), each = 20)),
  IC = c(rep(ICs[[1]], 20), rep(ICs[[2]], 20), rep(ICs[[3]], 20))
)

# Tracé du graphique PACF avec IC multiples
ggplot(df_pacf, aes(x = lag, y = pacf)) +
  geom_hline(yintercept = 0, color = "black") +
  geom_segment(aes(xend = lag, yend = 0), color = "blue") +
geom_hline(aes(yintercept = IC, color = alpha), linetype = "dashed") +
geom_hline(aes(yintercept = -IC, color = alpha), linetype = "dashed") +
scale_color_manual(values = c("green", "blue", "red")) + labs(title =
"PACF ipc_global avec IC à 90%, 95% et 99%", y = "PACF", color = "Niveau
de confiance") +
  theme_minimal()
```

```
ICs_pacf <- round(z_vals / sqrt(n), 4)

data.frame(
  "Niveau de confiance" = paste0(alpha_levels * 100,
  "%"), "Borne inférieure" = -ICs_pacf,
  "Borne supérieure" = ICs_pacf
)
```

#Estimation du modeles ARMA. #Divisons notre échantillon.

```
n1=lenght(resid_lisa3_ipc_haei)
n2=lenght(resid_lisa3_ipc_global)

taille_train1=round(n1*0.8)
entrainement_ipc_haei=resid_lisa3_ipc_haei[1:taille_train1]
test_ipc_haei=resid_lisa3_ipc_haei[(taille_train1+1):n1]

taille_train2=round(n2*0.8)
entrainement_ipc_global =resid_lisa3_ipc_global[1:taille_train2]
test_ipc_global = resid_lisa3_ipc_global[(taille_train2+1):n2]
```

#Estimons un modele ARMA(p, q).

```
#ipc_haei on a arma(0,1)
modèle1_ipc_haei=forecast::Arima(entrainement_ipc_haei, order=c(0,0,1))
modèle3_ipc_haei=forecast::Arima(test_ipc_haei, order=c(0,0,1))
#ipc_global on a arma(1,2)
modèle1_ipc_global=forecast::Arima(entrainement_ipc_global,
order=c(1,0,2))
modèle3_ipc_global=forecast::Arima(test_ipc_global, order=c(1,0,2))
```

#Estimons un second modèle qui est imbriqué au premier.


```
#ipc_haei imbriqué
modèle2_ipc_haei=forecast::Arima(entrainement_ipc_haei, order=c(1,0,1))
modèle4_ipc_haei=forecast::Arima(test_ipc_haei, order=c(1,0,1))
#ipc_global imbriqué
modèle2_ipc_global=forecast::Arima(entrainement_ipc_global,
order=c(0,0,2))
modèle4_ipc_global=forecast::Arima(test_ipc_global, order=c(0,0,2))
```

#Pour chacun des modèles estimons pour chacune des séries, préstentons les paramètres estimés et leurs ecartstypes dans un tableau.

```
extract_params <- function(model) {
  coefs <- coef(model)
  std_err <- sqrt(diag(vcov(model)))
  data.frame(
    Paramètre = names(coefs),
```

```
    Estimate = round(coefs, 4),
    `Écart-type` = round(std_err, 4)
  )
}
```

#Modèles ipc_global.

```
table_global_entrainement <- extract_params(modèle1_ipc_global)
table_global_test <- extract_params(modèle3_ipc_global)
table_global_imbrique_entrainement <- extract_params(modèle2_ipc_global)
table_global_imbrique_test <- extract_params(modèle4_ipc_global)
```

```
table_global_entrainement
```

```
table_global_test
```

```
table_global_imbrique_entrainement
```

```
table_global_imbrique_test
```

#Modèles ipc_haei.

```
table_haei_entrainement <- extract_params(modèle1_ipc_haei)
table_haei_test <- extract_params(modèle3_ipc_haei)
table_haei_imbrique_entrainement <- extract_params(modèle2_ipc_haei)
table_haei_imbrique_test <- extract_params(modèle4_ipc_haei)
```

#Tests diagnostiques.

#Calculons l'AIC et le BIC. #Echantillon entrainenement

```
AIC(modèle1_ipc_haei); BIC(modèle1_ipc_haei)
```

```
AIC(modèle2_ipc_haei); BIC(modèle1_ipc_haei)
```

```
AIC(modèle1_ipc_global); BIC(modèle1_ipc_global)
```

```
AIC(modèle2_ipc_global); BIC(modèle2_ipc_global)
```

#Echantillon de test.


```
modèle3_ipc_haei
```

```
AIC(modèle3_ipc_haei); BIC(modèle3_ipc_haei)
```

```
AIC(modèle4_ipc_haei); BIC(modèle4_ipc_haei)
```

```
AIC(modèle3_ipc_global); BIC(modèle3_ipc_global)
```

```
AIC(modèle4_ipc_global); BIC(modèle4_ipc_global)
```

#Calculons la statistique du ratio de vraisemblances et calculez la valeur-p associee.
Series d'entrainement. # Série ipc_haei.

```
lrtest(modèle1_ipc_haei,modèle2_ipc_haei)
```

Série ipc_global.

```
lrtest(modèle1_ipc_global,modèle2_ipc_global)
```

#Series de Test # Série ipc_haei.

```
lrtest(modèle3_ipc_haei,modèle4_ipc_haei)
```

Série ipc_global.

```
lrtest(modèle3_ipc_global,modèle4_ipc_global)
```

#calculons les valeurs ajustées dans l'échantillon sur l'ensemble d'entrainement et faisons des prédictions hors échantillon sur l'ensemble de test.

Série ipc_global.

Les valeurs ajustées dans l'échantillon sur l'ensemble d'entrainement.

```
val_ajust1 <- fitted(modèle1_ipc_global)
val_ajust2 <- fitted(modèle2_ipc_global)
```

Les erreurs quadratiques moyennes.

```
erreur_quadr_entrainement1 <- sqrt(mean(entrainement_ipc_global -
val_ajust1)^2)
erreur_quadr_entrainement2 <- sqrt(mean(entrainement_ipc_global -
val_ajust2)^2)
```

Les prédictions hors échantillon sur l'ensemble de test

```
predic1 <- forecast::forecast(modèle1_ipc_global, h =
length(test_ipc_global))$mean
```



```
predic2 <- forecast::forecast(modèle2_ipc_global, h =
length(test_ipc_global))$mean
```

Les erreurs quadratiques moyennes, analyse des valeurs ajustées et des prédictions.

```
erreur_test1 <- sqrt(mean((test_ipc_global - predic1)^2))
erreur_test2 <- sqrt(mean((test_ipc_global - predic2)^2))
```

```
cat("erreur_entrainement1 :",erreur_quadr_entrainement1 , "\n")
```

```
cat("erreur_test1:", erreur_test1 , "\n")
```

```
cat("erreur_entrainement2 :", erreur_quadr_entrainement2, "\n")
```

```
cat("erreur_test2 :", erreur_test2, "\n")
```

Série ipc haei.

Les valeurs ajustées dans l'échantillon sur l'ensemble d'entrainement.

```
val_ajust3 <- fitted(modèle1_ipc_haei)
val_ajust4 <- fitted(modèle2_ipc_haei)
```

Les erreurs quadratiques moyennes.

```
erreur_quadr_entrainement3 <- sqrt(mean(entrainement_ipc_haei -
val_ajust3)^2)
erreur_quadr_entrainement4 <- sqrt(mean(entrainement_ipc_haei -
val_ajust4)^2)
```

Des prédictions hors échantillon sur l'ensemble de test

```
predic3 <- forecast::forecast(modèle3_ipc_haei, h =
length(test_ipc_haei))$mean
predic4 <- forecast::forecast(modèle3_ipc_haei, h =
length(test_ipc_haei))$mean
```

Les erreurs quadratiques moyennes, analyse des valeurs ajustées et des prédictions.

```
erreur_test3 <- sqrt(mean((test_ipc_haei - predic3)^2))
erreur_test4 <- sqrt(mean((test_ipc_haei - predic4)^2))
```

```
cat("erreur_entrainement1 :",erreur_quadr_entrainement3 , "\n")
```



```
cat("erreur_test1:", erreur_test3 , "\n")
```

```
cat("erreur_entrainement2 :", erreur_quadr_entrainement4, "\n")
```

```
cat("erreur_test2 :", erreur_test4, "\n")
```

#Modèle bivarié et corrélations croisées. #approximons chacune des séries

d'innovations avec l'algorithme des innovations.

```
l <- function(x, q, m = 17) {
  if (q < 1)
    stop("q < 1")

  x = x - mean(x)
  gamma = acvf(x, m + 1)
  kappa = function(i, j) gamma[abs(i - j) + 1]
  Theta = matrix(0, m, m)
  v = numeric(m + 1)
  v[1] = kappa(1, 1)

  for (n in 1:m) {
    for (k in 0:(n - 1)) {
      if (k == 0) {
        s = 0
      } else {
        s = sum(Theta[k, k:1] * Theta[n, n:(n - k + 1)] * v[1:k])
      }
      Theta[n, n - k] = (kappa(n + 1, k + 1) - s)/v[k + 1]
    }
    s = sum(Theta[n, n:1]^2 * v[1:n])
    v[n + 1] = kappa(n + 1, n + 1) - s
  }

  theta = Theta[m, 1:q]
  n = length(x)
  se.theta = numeric(q)
  se.theta[1] = sqrt(1/n)
  if (q > 1) {
    for (j in 2:q) {
      se.theta[j] = sqrt((1 + sum(Theta[m, 1:(j - 1)]^2))/n)
    }
  }
  sigma2 = v[m + 1]

  # Estimer les innovations (résidus)
  eps = numeric(n)
  for (t in (q + 1):n) {
    eps[t] = x[t] - sum(theta * rev(eps[(t - q):(t - 1)]))
  }

  # Moyenne des innovations
  mean_innov = mean(eps[(q + 1):n]) # on ignore les premiers NA
```



```
  # Autocorrélation des innovations
  acf_innov = acf(eps[(q + 1):n], plot = FALSE)$acf

  # Objet de sortie
  a = list(
    v = v,
    phi = 0,
```

```
    theta = theta,
    sigma2 = sigma2,
    aicc = NA,
    se.phi = 0,
    se.theta = se.theta,
    innov = eps,
    mean_innov = mean_innov,
    acf_innov = acf_innov
  )

  return(a)
}
```

#Analysons les propritiés statistiques des innovations obtenues (moyenne, variance, autocorrelation), et Calculons la fonction de corrélation croisée (CCF) entre les résidus des modèles ARMA(p, q) des deux séries.

#ipc global.

```
res_global <- l(test_ipc_global, 2)

# Récupérer les innovations
innov_global <- res_global$innov

# Vérifier que les innovations existent
if (!is.null(innov_global)) {
  # Moyenne
  moyenne <- mean(innov_global)
  cat("Moyenne des innovations :", moyenne, "\n")

  # Variance
  variance <- var(innov_global)
  cat("Variance des innovations :", variance, "\n")

  # Autocorrélation (jusqu'au lag 20)
  acf_res <- acf(innov_global, lag.max = 20, plot = FALSE)
  autocorr <- acf_res$acf
  print("Autocorrélation des innovations :")
  print(autocorr)
} else {
  cat("Les innovations n'ont pas été générées correctement.\n")
}
```

#ipc_haei.


```
res_haei <- l(test_ipc_haei, 1)

innov_haei <- res_haei$innov

# Vérifier que les innovations existent
if (!is.null(innov_haei)) {
```

```
  # Moyenne
  moyenne <- mean(innov_haei)
  cat("Moyenne des innovations :", moyenne, "\n")

  # Variance
  variance <- var(innov_haei)
  cat("Variance des innovations :", variance, "\n")

  # Autocorrélation (jusqu'au lag 20)
  acf_res <- acf(innov_haei, lag.max = 20, plot = FALSE)
  autocorr <- acf_res$acf
  print("Autocorrélation des innovations :")
  print(autocorr)
} else {
  cat("Les innovations n'ont pas été générées correctement.\n")
}
```

#Représentation graphique de la fonction de corrélation croisée (CCF).

```
ccff <-function (x, y, lag.max = NULL, type = c("correlation",
"covariance"),
  plot = TRUE, na.action = na.fail, ...)
{
  type <- match.arg(type)
  if (is.matrix(x) || is.matrix(y))
    stop("univariate time series only")
  X <- ts.intersect(as.ts(x), as.ts(y))
  colnames(X) <- c(deparse(substitute(x))[1L], deparse(substitute(y))[1L])
  acf.out <- acf(X, lag.max = lag.max, plot = FALSE, type = type,
  na.action = na.action)
  lag <- c(rev(acf.out$lag[-1, 2, 1]), acf.out$lag[, 1, 2])
  y <- c(rev(acf.out$acf[-1, 2, 1]), acf.out$acf[, 1, 2])
  acf.out$acf <- array(y, dim = c(length(y), 1L, 1L))
  acf.out$lag <- array(lag, dim = c(length(y), 1L, 1L))
  acf.out$snames <- paste(acf.out$snames, collapse = " & ")
  if (plot) {
    plot(acf.out, ...)
    return(invisible(acf.out))
  }
  else return(acf.out)
}
ccff(innov_haei, innov_global)
```

Testons si les résidus de chaque série sont effectivement non corrélés en utilisant un test de Ljung-Box appliqué aux séries croisées.


```
Box.test(ccf(innov_haei, innov_global, plot=FALSE)$acf, type="Ljung-Box",
lag=10)
```